

Mortalidad por cáncer de pulmón en Ohio (décadas de 1960 a 1980)

Maria Paula Camargo Rincon* Laura Katherine Martínez Castiblanco†

Contents

1	Introducción	1
2	Análisis descriptivo	3
3	Modelo y verificación de supuestos	9
4	Verificación de supuestos	12
4.1	<i>Independencia:</i>	12
4.2	<i>Normalidad:</i>	13
4.3	<i>Hetercedasticidad:</i>	14
5	Conclusiones	14
6	Bibliografía	14

1 Introducción

Este conjunto de datos se deriva de un estudio de mortalidad por cáncer de pulmón en Ohio realizado entre 1969 y 1971 a nivel de condado. La base de datos `ohiolung` contiene información para los 88 condados del estado de Ohio, (EE. UU.). La base de datos proviene del GeoDa (Center for Geospatial Analysis and Computation) y presenta 42 variables. En las estas se presentan datos referentes a la mortalidad por cáncer de pulmón estratificada por género (masculino/femenino) y raza (blanca/negra), junto variables geográficas básicas.

*mcamargori@unal.edu.co

†laumartinezca@unal.edu.co

La siguiente tabla resume las variables principales de la base de datos:

=====

Table 1: Definición de variables principales en la base de datos
ohlung.shp

Variable	Descripcion
CountyID	ID secuencial del condado (orden alfabético)
NAME	Nombre del condado
FIPSNO	Código FIPS del condado (numérico)
AREA	Área del polígono (condado)
PERIMETER	Perímetro del polígono (condado)
RECORD_ID	ID único del registro
COUNTYID	ID del condado
LGRyy	Casos de cáncer de pulmón para género G (M/F) y raza R (W/B) en año yy (1968, 1978, 1988)
POPGRyy	Población en riesgo para género G y raza R en año yy
LGyy	Total de casos de cáncer de pulmón por género G en año yy
POPGyy	Población total en riesgo por género G en año yy

Hay 12 variables por año (4 combinaciones de género-raza $\times$ 3 tipos: casos detallados, población detallada, totales por género)

Table 2: Primeros 6 datos de la base de datos original.

COUNTYID	NAME	FIPSNO	AREA	PERIMETER	LMW68	POPMW68	LMB68
48	Lucas	39095	873382000	164533	128	205421	19
26	Fulton	39051	1054690000	134891	4	15521	0
28	Geauga	39055	1005750000	146204	4	30415	0
86	Williams	39171	1089180000	136740	5	16252	0
18	Cuyahoga	39035	1242480000	173664	435	677185	87
62	Ottawa	39123	634883000	128356	10	17638	0

POPMB68	LM68	POPM68	LFW68	POPFW68	LFB68	POPFB68	LF68	POPF68	LMW78
25956	147	231377	27	220106	1	28527	28	248633	149
50	4	15571	1	16358	0	47	1	16405	10
472	4	30887	3	31131	0	496	3	31627	11
24	5	16276	0	17216	0	20	0	17236	7
157046	522	834231	88	734014	23	176614	111	910628	442
164	10	17802	0	18430	0	182	0	18612	8

POPMW78	LMB78	POPMB78	LM78	POPM78	LFW78	POPFW78	LFB78	POPFB78
194976	34	30252	183	225228	48	210307	4	33790
18268	0	75	10	18343	3	19080	0	70
35839	1	604	12	36443	3	36148	0	619
17678	1	44	8	17722	0	18126	0	70

567350	138	161461	580	728811	165	623107	36	186806
19756	0	170	8	19926	6	20388	0	188

LF78	POPF78	LMW88	POPMW88	LMB88	POPMB88	LM88	POPM88	LFW88
52	244097	150	185367	39	36104	189	221471	108
3	19150	8	18600	1	62	9	18662	2
3	36767	17	37759	1	1051	18	38810	12
0	18196	10	17822	0	61	10	17883	7
201	809913	453	499655	188	178432	641	678087	269
6	20576	16	19164	0	205	16	19369	9

POPFW88	LFB88	POPFB88	LF88	POPF88
200458	8	41115	116	241573
19444	0	65	2	19509
37973	0	1040	12	39013
18506	0	110	7	18616
552388	83	207628	352	760016
20063	1	221	10	20284

Se realizó una modificación del formato de la tabla para poder trabajar con las variables sexo (Femenino, Masculino), año(1968, 1978, 1988) y raza (Blanco, Negro)

Table 7: Vista primeros 15 datos en formato largo

COUNTYID	NAME	AREA	PERIMETER	gender	race	year	cases	pop
48	Lucas	873382000	164533	Male	White	1968	128	205421
48	Lucas	873382000	164533	Female	White	1968	27	220106
48	Lucas	873382000	164533	Male	Black	1968	19	25956
48	Lucas	873382000	164533	Female	Black	1968	1	28527
48	Lucas	873382000	164533	Male	White	1978	149	194976
48	Lucas	873382000	164533	Female	White	1978	48	210307
48	Lucas	873382000	164533	Male	Black	1978	34	30252
48	Lucas	873382000	164533	Female	Black	1978	4	33790
48	Lucas	873382000	164533	Male	White	1988	150	185367
48	Lucas	873382000	164533	Female	White	1988	108	200458
48	Lucas	873382000	164533	Male	Black	1988	39	36104
48	Lucas	873382000	164533	Female	Black	1988	8	41115
26	Fulton	1054690000	134891	Male	White	1968	4	15521
26	Fulton	1054690000	134891	Female	White	1968	1	16358
26	Fulton	1054690000	134891	Male	Black	1968	0	50

2 Análisis descriptivo


En esta sección se realiza una exploración de la base de datos con tal de identificar relaciones entre las variables y establecer la estructura inicial del modelo de regresión lineal múltiple.




Para ello inicialmente se analizan los datos en la estructura original y posteriormente se analiza la base de datos con la nueva estructura propuesta.

A continuación se presentan gráficos descriptivos asociados al último año registrado en la base de datos con la estructura original. Se observa una alta variabilidad en el número de casos, con desviaciones estándar frecuentemente superiores a las medias. Los promedios de casos son consistentemente más altos en hombres que en mujeres y en la población blanca respecto a la negra.


Evaluando las distribuciones, se observa una asimétrica a la derecha en cada grupo de la población evaluada, dicionalmente se evidencia que los condados más poblados tienden a presentar menos riesgo de cáncer de pulmón, muy seguramente por la separación de zonas urbanas y rurales.

Adicionalmente, se evidencia un comportamiento similar para los dos años anteriores registrados, salvo por un incremento temporal en el número promedio de casos entre 1968 y 1988.






Con base en lo anterior y llegar a cumplir con el requisito de incluir al menos una variable cualitativa, y teniendo en cuenta las observaciones anteriores, se reestructuraron los datos al formato largo utilizando exclusivamente las variables originales de la base de datos como se presentó al inicio.



Notese que tenemos de 1056 observaciones, 386 son 0 casos, esto puede representar un problema más adelante en los modelos, ya que puede tender a inflar la varianza.

```
## # A tibble: 1 x 1
##   count
##   <int>
## 1    386
```

Considerando la nueva estructura de los datos se realiza un análisis adicional sobre la variable respuesta **cases** para evaluar su comportamiento en función del género y el año.




Alta correlación entre casos y población, se presenta correlación moderadamente alta entre el área y el perímetro. En las correlaciones parciales podemos ver que la relación entre las

variables independientes, área y perímetro, y las variables dependientes, casos y población, tienen una correlación baja con las demás variables.

Se destaca en los gráficos de dispersión que a pesar de que la correlación alta moderada entre *Área* y *Perímetro*, las variables *Casos* y *Población* se comportan igualmente diferente en ambas variables, es decir, para *Casos* y *Población* se puede ver que hay más dispersión con la variable *Área* que con la variable *Perímetro*.

El coeficiente empleado en este gráfico es el coeficiente de correlación lineal de Pearson,




```
## Warning in styling_latex_scale(out, table_info, "down"): Longtable cannot be
## resized.
```


Table 8: Tasas de incidencia por variable categórica

categoria	conteo
Female	0.1
Male	0.4
Black	0.3
White	0.2
1968	0.1
1978	0.2
1988	0.2

Presencia de datos atípicos por años, mas dispersión conforme pasan los años, sin embargo la media parece mantenerse. Más dispersos en hombres que mujeres pero media constante, más datos atípicos por hombres que por mujeres.



Podemos ver que por condado va aumentando los casos cada año evaluado.



Podemos ver más registros o casos en los hombres que en las mujeres en los distintos años y condados.

Table 9: Top 15 condados con mas casos

NAME	total_casos	area
Cuyahoga	2407	1242480000
Hamilton	1435	1084790000

Franklin	1146	1442010000
Montgomery	791	1210680000
Summit	759	1093150000
Lucas	715	873382000
Stark	495	1499940000
Mahoning	453	1077280000
Butler	330	1214420000
Lorain	303	1306670000
Trumbull	293	1635690000
Lake	278	611960000
Clark	211	1030010000
Jefferson	172	1032610000
Licking	157	1779800000

3 Modelo y verificación de supuestos

Considerando el análisis anterior se plantea el siguiente modelo:

$$\text{cases} = \beta_0 + \beta_1 \text{AREA} + \beta_2 \text{PERIMETER} + \beta_3 \text{genderMale} + \beta_4 \text{year1978} + \beta_5 \text{year1978} + \beta_6 \text{pop} + \epsilon$$

donde **cases** corresponde a las variables LMy o LFyy según el género y año, y **pop** es la población en riesgo correspondiente.

Los resultados de este modelo muestran que la población (**pop**) es altamente significativa y tiene el mayor impacto, como era esperado. El género masculino se asocia con un promedio de aproximadamente 26.8 casos adicionales respecto al femenino (controlando por las demás variables). Además, se observa un aumento significativo en el número de casos en 1978 y 1988 respecto a 1968.

```
##
## Call:
## lm(formula = cases ~ AREA + PERIMETER + gender + year + pop,
##     data = ohlung_long)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -245.595   -5.538   -0.540    5.285   206.827
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.673e+01  5.205e+00  -3.214  0.00135 **
## AREA        -4.684e-09  3.268e-09  -1.433  0.15209
```

```
## PERIMETER      6.974e-05  4.282e-05   1.629  0.10372
## genderMale     1.338e+01  1.174e+00  11.400 < 2e-16 ***
## year1978       4.153e+00  1.437e+00   2.889  0.00394 **
## year1988       9.043e+00  1.437e+00   6.291 4.62e-10 ***
## pop            4.687e-04  8.418e-06  55.678 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 19.07 on 1049 degrees of freedom
## Multiple R-squared:  0.7587, Adjusted R-squared:  0.7573
## F-statistic: 549.6 on 6 and 1049 DF,  p-value: < 2.2e-16
```

Las variables AREA y PERIMETER no resultan estadísticamente significativas. Un modelo reducido sin estas variables geográficas presenta un R^2 prácticamente idéntico (0.7605 vs 0.7613), lo que confirma su escaso aporte y se propone en cambio el siguiente modelo reducido:

$$\text{cases} = \beta_0 + \beta_1 \text{genderMale} + \beta_2 \text{year1978} + \beta_3 \text{year1988} + \beta_4 \text{pop} + \epsilon$$

```
##
## Call:
## lm(formula = cases ~ gender + year + pop, data = ohlung_long)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -245.236   -5.946   -0.724    5.250   207.439
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.159e+01  1.203e+00  -9.641 < 2e-16 ***
## genderMale   1.338e+01  1.174e+00  11.397 < 2e-16 ***
## year1978     4.153e+00  1.438e+00   2.888  0.00396 **
## year1988     9.042e+00  1.438e+00   6.288 4.71e-10 ***
## pop          4.698e-04  8.387e-06  56.013 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 19.08 on 1051 degrees of freedom
## Multiple R-squared:  0.758, Adjusted R-squared:  0.7571
## F-statistic: 823 on 4 and 1051 DF,  p-value: < 2.2e-16
```

Además de esto, hemos realizado regresión por ridge y lasso mostradas a continuación:

```
## 9 x 1 sparse Matrix of class "dgCMatrix"
```

```
##                                s0
## (Intercept) -8.310004e+02
## COUNTYID    -2.517259e-02
## NAME        .
## AREA        -3.987997e-09
## PERIMETER    7.181817e-05
## gender       .
## race         .
## year         4.178378e-01
## pop          4.302289e-04
```

La regresión ridge mostro que las variables que tienen un impacto casi nulo en la variable respuesta son: gender y NAME.

```
## 9 x 1 sparse Matrix of class "dgCMatrix"
##                                s0
## (Intercept) -1.014047e+02
## COUNTYID    .
## NAME        .
## AREA        .
## PERIMETER    .
## gender       .
## race         .
## year         5.175070e-02
## pop          4.217329e-04
```

Por otro lado el modelo de regresión lasso indica que las variables que son influyentes son: 'year' y 'pop'. Por lo que en el modelo final se ha tomado la decisión de tener como variables explicativas: gender, year y pop.

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \epsilon$$


$$\text{cases} = \beta_0 + \beta_1 \text{genderMale} + \beta_2 \text{year1978} + \beta_3 \text{year1988} + \beta_4 \text{pop} + \epsilon$$

donde:

- x_{i1} es la variable dummy referente al género masculino, es decir, 1 si es masculino 0 en otro caso.
- x_{i2} es la variable dummy referente al año de 1978.
- x_{i3} es la variable dummy referente al año de 1988.
- x_{i4} es la variable numérica de la población en riesgo.


4 Verificación de supuestos

Para un primer avistamiento sobre la validación del modelo veamos el comportamiento de los residuales:



Podemos ver que hay un problema evidente de heteroscedasticidad que más adelante será confirmado con las respectivas pruebas.

4.1 *Independencia:*




Parecen haber algunas correlaciones entre los residuales.

##

```
## Durbin-Watson test
##
## data:  modelo_2
## DW = 2.6646, p-value = 1
## alternative hypothesis: true autocorrelation is greater than 0
```

Debido a que su p valor fue mayor al nivel de significancia (0.05), nos indica que no se rechaza H_0 no hay autocorrelación en los residuales, aunque el ACF sugiere algunas correlaciones en ciertos rezagos, la prueba de Durbin–Watson no encuentra evidencia estadística suficiente para rechazar la hipótesis de independencia al 5%.

4.2 Normalidad:



Con este histograma no podemos asegurar que la distribución de los residuales sea una normal, sin embargo se ve que es una distribución simétrica, y con media en 0. Por otro lado el qqplot nos muestra que puede presentar problemas de normalidad.

```
##
## Shapiro-Wilk normality test
##
## data:  residuals.lm(modelo_2)
## W = 0.55669, p-value < 2.2e-16
```

Con un p valor menor al nivel de significancia (0.05) se rechaza la H_0 la población viene de una distribución normal.

4.3 *Hetercedasticidad:*

Para evaluar la heteroscedasticidad formalmente, tomando en cuenta que la población no sigue o proviene de una distrinción normal, se decidió aplicar el test de Breusch-pagan.

```
##  
## studentized Breusch-Pagan test  
##  
## data:  modelo_2  
## BP = 488.1, df = 4, p-value < 2.2e-16
```

Con un p valor menor al nivel de significancia (0.05) se rechaza la H_0 igualdad de varianzas, es algo que ya se podría detectar a simple vista en el gráfico de los residuales y los valores predichos.

5 Conclusiones

- La regresión lineal normal no parece la mejor opción para este caso, probablemente se acomodarían mejor los datos a un modelo de regresión lineal generalizado con distribución poisson.
- Debido a la falta de normalidad y homoscedasticidad los intervalos de confianza y las pruebas de significancia pueden ser no tan precisas.
- Faltó considerar la relación que hay entre condados, es decir una relación espacial.

6 Bibliografía