

Mortalidad por cáncer de pulmón en Ohio (décadas de 1960 a 1980)

Maria Paula Camargo Rincon* Laura Katherine Martínez Castiblanco†

Contents

1	Introducción	1
1.1	Exploración espacial	5
2	Matrices W	13
3	Modelado Espacial de Cáncer de Pulmón (1988)	13
3.1	Selección de Variables	13
3.2	Evaluación y Selección de la Matriz W	13
3.3	1. Comparación Estructural y Topológica	16
3.4	2. Diagrama de Dispersión de Moran (Moran Scatterplot)	17
3.5	3. Exploración de Promedios Móviles Espaciales	18
3.6	4. Análisis de Eigenvectores (MESF/MEM)	19
3.7	5. Pruebas de Diagnóstico para Selección del Modelo (LM Tests)	20
3.7.1	Las Pruebas Simples (RSerr y RSlag)	20
3.7.2	Las Pruebas Robustas (¡Las que mandan aquí!)	20

1 Introducción

Este conjunto de datos se deriva de un estudio de mortalidad por cáncer de pulmón en Ohio realizado entre 1968 y 1978 a nivel de condado. La base de datos `ohiolung` contiene información para los 88 condados del estado de Ohio, (EE. UU.). La base de datos proviene

*mcamargori@unal.edu.co

†laumartinezca@unal.edu.co

del GeoDa (Center for Geospatial Analysis and Computation) y presenta 42 variables. En las estas se presentan datos referentes a la mortalidad por cáncer de pulmón estratificada por género (masculino/femenino) y raza (blanca/negra), junto variables geográficas básicas.

La siguiente tabla resume las variables principales de la base de datos:

Table 1: Definición de variables principales en la base de datos ohlung.shp

Variable	Descripcion
CountyID	ID secuencial del condado (orden alfabético)
NAME	Nombre del condado
FIPSNO	Código FIPS del condado (numérico)
AREA	Área del polígono (condado)
PERIMETER	Perímetro del polígono (condado)
RECORD_ID	ID único del registro
COUNTYID	ID del condado
LGryy	Casos de cáncer de pulmón para género G (M/F) y raza R (W/B) en año yy (1968, 1978, 1988)
POPGRyy	Población en riesgo para género G y raza R en año yy
LGyy	Total de casos de cáncer de pulmón por género G en año yy
POPGyy	Población total en riesgo por género G en año yy

Se realizó una modificación del formato de la tabla para poder trabajar con las variables sexó (Femenino, Masculino), año(1968, 1978, 1988) y raza (Blanco, Negro)

Table 2: Vista de los datos en formato largo

NAME	AREA	PERIMETER	gender	race	year	cases	pop
Adams	1536060000	172801	Male	White	1968	6	8912
Adams	1536060000	172801	Female	White	1968	0	8994
Adams	1536060000	172801	Male	Black	1968	0	24
Adams	1536060000	172801	Female	Black	1968	0	22
Adams	1536060000	172801	Male	White	1978	7	11842
Adams	1536060000	172801	Female	White	1978	6	11996
Adams	1536060000	172801	Male	Black	1978	0	41
Adams	1536060000	172801	Female	Black	1978	0	38
Adams	1536060000	172801	Male	White	1988	13	12443
Adams	1536060000	172801	Female	White	1988	2	12850

```
## # A tibble: 1 x 1
##   count
## * <int>
## 1    386
```

Notese que tenemos de 1056 observaciones, 386 son 0 casos, esto puede representar un problema más adelante en los modelos, ya que puede tender a inflar la varianza.






Table 3: Tasas de incidencia por variable categórica

categoría	conteo
Female	0.1010566
Male	0.3876166
Black	0.2652797
White	0.2233935
1968	0.1017415
1978	0.1636140
1988	0.2233177

En el primer gráfico



En general los totales de casos y poblaciones en los distintos años se comportan de manera lineal.




Podemos ver más registros o casos en los hombres que en las mujeres en los distintos años y condados.


Table 4: Top 15 condados con tasas más altas

NAME	total_tasas	area
Williams	0.0243703	1089180000
Meigs	0.0237038	1089800000
Fulton	0.0176855	1054690000
Morgan	0.0159628	1081310000
Pike	0.0159304	1128210000
Crawford	0.0152284	1013780000
Muskingum	0.0112092	1722120000
Washington	0.0097122	1626890000
Tuscarawas	0.0090480	1488060000
Brown	0.0089926	1272420000
Shelby	0.0086664	1049430000
Jefferson	0.0085801	1032610000
Belmont	0.0080245	1387480000
Gallia	0.0079639	1230960000
Marion	0.0076424	1036070000

1.1 Exploración espacial




Podemos ver que en los años se ha presentado un aumento de la tasa de incidencia de cancer de pulmón.




En este se realizó una diferencia de las tasas en los años, tal diferencia significa que si es positiva quiere decir que aumento, y si es negativa quiere decir que disminuyó. Podemos ver que comparando las tasas de los años de 1968 y 1988, casi no hay tasas negativas, lo que indica que en general entre 1968 y 1988 hubo un aumento de casos de cancer de pulmón. Por otro lado comparando los años 1968 y 1978, podemos ver más condados con tasas negativas, lo que indica que hubo una disminución, esto es importante porque si bien vimos en el anterior mapa que la tasa aumentaba conforme los años, no quiere decir que en todos los contados hubo un aumento. Por último entre los años 1978 y 1988 podemos ver que fueron más constantes las tasas, es decir que no hubo un aumento significativo en la mayoría de condados (resaltados por el verde claro), además tambien podemos ver que hay tasas que siguieron disminuyendo (morado).


Blanca 1968




Blanca 1978




Blanca 1988





Negra 1968



Negra 1978




Negra 1988



Algo notorio que podemos observar, es la tasa constante de las personas negras con cancer de pulmón en el mapa de cada año, es decir, que no hay tanta varianción entre condados, también se ve que las tasas de la población negra son mayores que las tasas de la población blanca, además con el paso de los años aumenta.

En general se ve un aumento en las tasas de cancer de pulmón, más notoriamente en la población de blancos que en la población de negros.



Algo que se debe resaltar es que hay un aumento en las tasas tanto de hombres como de mujeres entre 1978 y 1988.

Table 5: Correlación de pearson

[illegible]

AREA	POPFB68	POPFB78	POPFB88	POPFW68	POPFW78	POPFW88	POPMB68	POPMB78	POPMB88	POPMT68	POPMT78	POPMT88	POPOT68	POPOT78	POPOT88	POPOT88	RESP	tasa	pop	total	68	78	88
LM88	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.007																						
LM88	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.008																						
LM78	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.02																						
LM68	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.023																						
tasa	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.037																						
tasa	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001
tasa	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001	0.001

Table 6: Top 15 de Correlaciones de Pearson más Fuertes

Variable 1	Variable 2	Coefficiente (r)
pop_total68	POPF68	1
pop_total68	POPM68	1
pop_total78	POPF78	1
pop_total78	POPM78	1
pop_total88	POPF88	1
pop_total	POPF78	1
pop_total88	POPM88	1
pop_total	pop_total78	1
POPFW68	POPFW68	1
POPF68	POPM68	1
POPFW78	POPFW78	1
POPFB68	POPMB68	1
POPFB78	POPMB78	1
POPF78	POPM78	1
POPFW88	POPFW88	1


Lo que podemos destacar de la tabla es:

- Podemos evidenciar que área y perímetro solo tienen una fuerte correlación lineal entre ellas, mientras que con el resto de las variables (incluyendo la variable respuesta) presentan una correlación baja, por lo que no serán seleccionadas para el modelo.

- Las variables explicativas originales presentan alta correlación entre sí, por lo que solo se conservará variables que guarden la información de sexo, y raza.

Variables explicativas seleccionadas:

- *LMW68*: Número de casos de cáncer de pulmón en hombres blancos en el año de 1968.
- *LMW78*: Número de casos de cáncer de pulmón en hombres blancos en el año de 1978.
- *LFW68*: Número de casos de cáncer de pulmón en mujeres blancos en el año de 1968.
- *LFW78*: Número de casos de cáncer de pulmón en mujeres blancos en el año de 1978.



2 Matrices W

De acuerdo con la tabla, podemos ver en la mayoría (16 de 20) el valor p es menor al nivel de significancia ($\alpha = 0.05$), por lo cual se rechaza la hipótesis nula de independencia espacial, lo cual evidencia correlación espacial en los datos, teniendo en cuenta que hubo casos específicos en los que no se rechaza esa hipótesis nula, puede entenderse como que no en todas las configuraciones la dependencia espacial es consistente.

Por otro lado como en este caso estamos manejando condados (regiones) se decidió optar por usar la matriz de pesos de vecindad por el criterio reina, ya que entre la matriz reina y torre, con pesos y binarias (en cada caso), la matriz de reina con pesos es la que tiene menor p valor.

3 Modelado Espacial de Cáncer de Pulmón (1988)

3.1 Selección de Variables

Para modelar los datos de área de forma adecuada, la estructura del modelo debe seguir una lógica epidemiológica de conteo:

- **Variable Dependiente (Y):** `casos_totales88`. Representa el número total de casos observados en el condado durante 1988.
 - Se recomienda incluir la tendencia histórica `tasa_78` para capturar la inercia temporal.

3.2 Evaluación y Selección de la Matriz W

La elección de W no es arbitraria; se debe seleccionar aquella que maximice la captura de la dependencia espacial en los datos de 1988.

Según el sustento teórico, la matriz de pesos puede basarse en la similitud de una variable X altamente relacionada con la respuesta Z . Para esto, definimos $w_{ij} = 1/(x_i - x_j)$, donde x es la variable con mayor correlación con la tasa de cáncer de 1988.

Se evalúan cuatro tipos de estructuras:

- **Contigüidad Física:** Rook (Torre) y Queen (Reina).
- **Basadas en Distancia:** k -vecinos más cercanos con $k = 3, 4, 5, 6, 7, 8, 9, 10$.
- **Basada en Atributos:** Ponderación por diferencia de tasas históricas (similitud epidemiológica).


##		Matriz	Moran_I	p_valor
## 11		KNN8	0.1548626	0.0006544528
## 12		KNN9	0.1434494	0.0006975868
## 13		KNN10	0.1299191	0.0010611124
## 10		KNN7	0.1369917	0.0047958415
## 6		KNN3	0.2171337	0.0051126389
## 14	Variable_Weight		0.1355770	0.0054540392
## 8		KNN5	0.1600188	0.0068629705
## 7		KNN4	0.1771782	0.0077888556
## 9		KNN6	0.1249911	0.0174200927
## 1	Insumo.lw		0.1326041	0.0276046473
## 5	Insumo.lww		0.1326041	0.0276046473
## 3	Insumo.lwc		0.1060184	0.0648704404
## 2	Insumo.lwb		0.1060184	0.0648704404
## 4	Insumo.lwu		0.1060184	0.0648704404

Se evaluaron 10 estructuras de vecindad distintas. Todas resultaron significativas ($p < 0.05$), confirmando la existencia de conglomerados espaciales de cáncer de pulmón. La matriz de 8 vecinos más cercanos (KNN8) fue seleccionada por presentar la mayor significancia estadística ($p = 0.00065$), seguida por la matriz basada en atributos, lo que sugiere que la cercanía geográfica y la similitud en tasa_78 explican el patrón observado.

A continuación se presentan los mapas de clústeres LISA utilizando tanto la matriz seleccionada (KNN8).

```
##
## Moran I test under randomisation
##
## data:  ohlung$tasa_88
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 3.408, p-value = 0.0006545
## alternative hypothesis: two.sided
## sample estimates:
## Moran I statistic      Expectation      Variance
##      0.154862596      -0.011494253      0.002382796
```


NULL




3.3 1. Comparación Estructural y Topológica

Antes de modelar, es vital entender cómo “se ven” las conexiones espaciales. Una matriz de pesos espaciales (W) captura el arreglo geométrico de los valores en el mapa. Compararemos la matriz **KNN8** (seleccionada previamente) con una de contigüidad **Reina** para evaluar la densidad de la red.

Contigüidad Reina




K-Vecinos (k=8)



3.4 2. Diagrama de Dispersión de Moran (Moran Scatterplot)

Este gráfico visualiza la relación entre el valor de la tasa en un condado (z_i) y el promedio ponderado de sus vecinos ($\sum c_{ij}z_j$). * **Cuadrantes I y III:** Representan autocorrelación espacial positiva (Hotspots y Coldspots). * **Cuadrantes II y IV:** Representan autocorrelación negativa (Atípicos espaciales).


Dispersograma de Moran: Cáncer de Pulmón en Ohio (1988)



El diagrama de dispersión de Moran muestra una relación lineal positiva, ratificando la existencia de autocorrelación espacial. Se identifican condados como Monroe y Jefferson en el cuadrante Alto-Alto, actuando como núcleos de los clústeres de alta incidencia. Por el contrario, condados como Noble actúan como outliers espaciales, presentando tasas significativamente menores que el promedio de sus vecinos.


3.5 3. Exploración de Promedios Móviles Espaciales

La matriz W actúa como un **operador de rezago espacial**. Al calcular el promedio ponderado de los vecinos, suavizamos la variable para detectar tendencias regionales de largo alcance en lugar de ruido local.



3.6 4. Análisis de Eigenvectores (MESF/MEM)

La técnica **MESF** filtra la autocorrelación de los residuales y la transfiere al intercepto del modelo. Los eigenvectores representan patrones de mapas: los de valores propios altos muestran gradientes globales, mientras que los bajos muestran contrastes locales.



3.7 5. Pruebas de Diagnóstico para Selección del Modelo (LM Tests)

Para decidir si la dependencia espacial debe modelarse en la **variable dependiente** (Modelo de Rezago/Lag) o en los **términos de error** (Modelo de Error), utilizamos los Tests del Multiplicador de Lagrange sobre un modelo base de Mínimos Cuadrados.

Este resultado es muy interesante porque contradice lo que parecía un modelo “limpio” y revela una estructura espacial oculta que solo las pruebas robustas logran detectar.

3.7.1 Las Pruebas Simples (RSerr y RSlag)

- RSerr (Error): Tiene un p-valor de 0.7663. No es significativo.
- RSlag (Lag): Tiene un p-valor de 0.0622. Está muy cerca del límite (0.05), pero técnicamente no es significativo al 5%.

3.7.2 Las Pruebas Robustas (¡Las que mandan aquí!)

Cuando las pruebas simples fallan o son dudosas, miramos las ajustadas/robustas (adjRS). Estas pruebas controlan por la posible presencia de ambos tipos de dependencia espacial al mismo tiempo.

- adjRSerr ($p = 0.0060$): Muy significativo.

- adjRSlag ($p = 0.0009$): Extremadamente significativo.

A veces, un tipo de dependencia espacial (lag) “enmascara” a la otra (error). Las pruebas robustas limpian ese efecto mutuo.

Para elegir el modelo seguimos la regla de decisión de Anselin:

Si ambas pruebas robustas son significativas (como ocurre aquí), elegimos la que tenga el p-valor más pequeño o el estadístico más alto: adjRSlag ($p = 0.0009$) es mucho más pequeño que adjRSerr ($p = 0.0060$) un Modelo de Retardo Espacial (Spatial Lag Model - SAR).

Esto indica que, incluso después de controlar por población, raza y tasas históricas, la tasa de cáncer de un municipio sí está influenciada directamente por las tasas de sus vecinos. Existe un efecto de “derrame” o contagio espacial (spillover) que el modelo MCO no estaba captando.

Ejecuta este código para ajustar el modelo definitivo que ganaste en este test:

```
library(spatialreg)

##
## Attaching package: 'spatialreg'

## The following objects are masked from 'package:spdep':
##
##   get.ClusterOption, get.coresOption, get.mcOption,
##   get.VerboseOption, get.ZeroPolicyOption, set.ClusterOption,
##   set.coresOption, set.mcOption, set.VerboseOption,
##   set.ZeroPolicyOption

# Ajustamos el modelo de Retardo Espacial (SAR)
# modelo_sar <- lagsarlm(formula = mco_final$call$formula,
#                         data = ohlung,
#                         listw = W_seleccionada,,
#                         zero.policy = TRUE)
# # Ver los resultados finales
# summary(modelo_sar)
```

En el summary, busca el valor de Rho (ρ). Si es positivo y significativo, habrás confirmado matemáticamente que el cáncer de pulmón en Ohio se agrupa por vecindad más allá de lo que explican tus variables. ¿Te animas a ver si ese valor Rho sale significativo?