

Mortalidad por cáncer de pulmón en Ohio (décadas de 1960 a 1980)

Maria Paula Camargo Rincon* Laura Katherine Martínez Castiblanco†

Contents

1	Introducción	2
1.1	Exploración espacial	6
2	Matrices W	10
3	Modelado Espacial de Cáncer de Pulmón (1988)	10
3.1	Selección de Variables	10
3.2	Evaluación y Selección de la Matriz W	11
3.3	1. Comparación Estructural y Topológica	13
3.4	2. Diagrama de Dispersión de Moran (Moran Scatterplot)	14
3.5	3. Exploración de Promedios Móviles Espaciales	15
3.6	4. Análisis de Eigenvectores (MESF/MEM)	16
3.7	5. Pruebas de Diagnóstico para Selección del Modelo (LM Tests)	17
3.7.1	Las Pruebas Simples (RSerr y RSlag)	23
3.7.2	Las Pruebas Robustas (¡Las que mandan aquí!)	23
3.7.3	1. Modelo Poisson	24
3.7.4	<i>Independencia</i>	28
3.7.5	<i>Normalidad</i>	29
3.7.6	<i>Homocedasticidad</i>	30
3.7.7	1. Modelo quasi Poisson	31

*mcamargori@unal.edu.co

†laumartinezca@unal.edu.co

3.7.8	<i>Independencia</i>	36
3.7.9	<i>Normalidad</i>	37
3.7.10	<i>Homocedasticidad</i>	38
3.7.11	1. Binomial negativo	39
3.7.12	<i>Independencia</i>	44
3.7.13	<i>Normalidad</i>	45
3.7.14	<i>Homocedasticidad</i>	46
3.7.15	3. Comparación Visual de Predicciones	47
3.7.16	4. Autocorrelación Espacial en Residuales de Poisson	48

1 Introducción

Este conjunto de datos se deriva de un estudio de mortalidad por cáncer de pulmón en Ohio realizado entre 1968 y 1978 a nivel de condado. La base de datos `ohiolung` contiene información para los 88 condados del estado de Ohio, (EE. UU.). La base de datos proviene del GeoDa (Center for Geospatial Analysis and Computation) y presenta 42 variables. En las estas se presentan datos referentes a la mortalidad por cáncer de pulmón estratificada por género (masculino/femenino) y raza (blanca/negra), junto variables geográficas básicas.

La siguiente tabla resume las variables principales de la base de datos:

Table 1: Definición de variables principales en la base de datos
ohlung.shp

Variable	Descripción
CountyID	ID secuencial del condado (orden alfabético)
NAME	Nombre del condado
FIPSNO	Código FIPS del condado (numérico)
AREA	Área del polígono (condado)
PERIMETER	Perímetro del polígono (condado)
RECORD_ID	ID único del registro
COUNTYID	ID del condado
LGRyy	Casos de cáncer de pulmón para género G (M/F) y raza R (W/B) en año yy (1968, 1978, 1988)
POPGRyy	Población en riesgo para género G y raza R en año yy
LGyy	Total de casos de cáncer de pulmón por género G en año yy
POPGyy	Población total en riesgo por género G en año yy

Se realizó una modificación del formato de la tabla para poder trabajar con las variables `sexó` (Femenino, Masculino), `año`(1968, 1978, 1988) y `raza` (Blanco, Negro)

Table 2: Vista de los datos en formato largo

NAME	AREA	PERIMETER	gender	race	year	cases	pop
Adams	1536060000	172801	Male	White	1968	6	8912
Adams	1536060000	172801	Female	White	1968	0	8994
Adams	1536060000	172801	Male	Black	1968	0	24
Adams	1536060000	172801	Female	Black	1968	0	22
Adams	1536060000	172801	Male	White	1978	7	11842
Adams	1536060000	172801	Female	White	1978	6	11996
Adams	1536060000	172801	Male	Black	1978	0	41
Adams	1536060000	172801	Female	Black	1978	0	38
Adams	1536060000	172801	Male	White	1988	13	12443
Adams	1536060000	172801	Female	White	1988	2	12850

```
## # A tibble: 1 x 1
##   count
## * <int>
## 1    386
```

Notese que tenemos de 1056 observaciones, 386 son 0 casos, esto puede representar un problema más adelante en los modelos, ya que puede tender a inflar la varianza.





Table 3: Tasas de incidencia por variable categórica


categoría	conteo
Female	0.1010566
Male	0.3876166
Black	0.2652797
White	0.2233935

categoria	conteo
1968	0.1017415
1978	0.1636140
1988	0.2233177

En el primer gráfico



En general los totales de casos y poblaciones en los distintos años se comportan de manera lineal.




Podemos ver más registros o casos en los hombres que en las mujeres en los distintos años y condados.


Table 4: Top 15 condados con tasas más altas

NAME	total_tasas	area
Williams	0.0243703	1089180000
Meigs	0.0237038	1089800000
Fulton	0.0176855	1054690000
Morgan	0.0159628	1081310000
Pike	0.0159304	1128210000
Crawford	0.0152284	1013780000
Muskingum	0.0112092	1722120000
Washington	0.0097122	1626890000
Tuscarawas	0.0090480	1488060000
Brown	0.0089926	1272420000
Shelby	0.0086664	1049430000
Jefferson	0.0085801	1032610000
Belmont	0.0080245	1387480000
Gallia	0.0079639	1230960000
Marion	0.0076424	1036070000

1.1 Exploración espacial




Podemos ver que en los años se ha presentado un aumento de la tasa de incidencia de cancer de pulmón.




En este se realizó una diferencia de las tasas en los años, tal diferencia significa que si es positiva quiere decir que aumento, y si es negativa quiere decir que disminuyó. Podemos ver que comparando las tasas de los años de 1968 y 1988, casi no hay tasas negativas, lo que indica que en general entre 1968 y 1988 hubo un aumento de casos de cancer de pulmón. Por otro lado comparando los años 1968 y 1978, podemos ver más condados con tasas negativas, lo que indica que hubo una disminución, esto es importante porque si bien vimos en el anterior mapa que la tasa aumentaba conforme los años, no quiere decir que en todos los condados hubo un aumento. Por último entre los años 1978 y 1988 podemos ver que fueron más constantes las tasas, es decir que no hubo un aumento significativo en la mayoría de condados (resaltados por el verde claro), además tambien podemos ver que hay tasas que siguieron disminuyendo (morado).



Blanca 1968




Blanca 1978




Blanca 1988




Negra 1968



Negra 1978




Negra 1988



Algo notorio que podemos observar, es la tasa constante de las personas negras con cancer de pulmón en el mapa de cada año, es decir, que no hay tanta variación entre condados, también se ve que las tasas de la población negra son mayores que las tasas de la población blanca, además con el paso de los años aumenta.

En general se ve un aumento en las tasas de cancer de pulmón, más notoriamente en la población de blancos que en la población de negros.



Podemos ver que en ambos grupos se presenta variación a través de los condados, además de esto los hombres presentan tasas más altas de cancer de pulmón, las cuales aumentan conforme pasan los años.

Algo que se debe resaltar es que hay un aumento en las tasas tanto de hombres como de mujeres entre 1978 y 1988.


Lo que podemos destacar de la tabla es:


- Podemos evidenciar que área y perímetro solo tienen una fuerte correlación lineal entre ellas, mientras que con el resto de las variables (incluyendo la variable respuesta) presentan una correlación baja, por lo que no serán seleccionadas para el modelo.
- Las variables explicativas originales presentan alta correlación entre sí, por lo que solo se conservará variables que guarden la información de sexo, y raza.

Variables explicativas seleccionadas:

- *LMW68*: Número de casos de cáncer de pulmón en hombres blancos en el año de 1968.

- *LMW78*: Número de casos de cáncer de pulmón en hombres blancos en el año de 1978.
- *LFW68*: Número de casos de cáncer de pulmón en mujeres blancos en el año de 1968.
- *LFW78*: Número de casos de cáncer de pulmón en mujeres blancos en el año de 1978.





2 Matrices W

De acuerdo con la tabla, podemos ver en la mayoría (16 de 20) el valor p es menor al nivel de significancia ($\alpha = 0.05$), por lo cual se rechaza la hipótesis nula de independencia espacial, lo cual evidencia correlación espacial en los datos, teniendo en cuenta que hubo casos específicos en los que no se rechaza esa hipótesis nula, puede entenderse como que no en todas las configuraciones la dependencia espacial es consistente.

Por otro lado como en este caso estamos manejando condados (regiones) se decidió optar por usar la matriz de pesos de vecindad por el criterio reina, ya que entre la matriz reina y torre, con pesos y binarias (en cada caso), la matriz de reina con pesos es la que tiene menor p valor.

3 Modelado Espacial de Cáncer de Pulmón (1988)

3.1 Selección de Variables

Para modelar los datos de área de forma adecuada, la estructura del modelo debe seguir una lógica epidemiológica de conteo:

3.2 Evaluación y Selección de la Matriz W

La elección de W no es arbitraria; se debe seleccionar aquella que maximice la captura de la dependencia espacial en los datos de 1988.

Según el sustento teórico, la matriz de pesos puede basarse en la similitud de una variable X altamente relacionada con la respuesta Z . Para esto, definimos $w_{ij} = 1/(x_i - x_j)$, donde x es la variable con mayor correlación con la tasa de cáncer de 1988.

Se evalúan cuatro tipos de estructuras:

- **Contigüidad Física:** Rook (Torre) y Queen (Reina).
- **Basadas en Distancia:** k -vecinos más cercanos con $k = 3, 4, 5, 6, 7, 8, 9, 10$.
- **Basada en Atributos:** Ponderación por diferencia de tasas históricas (similitud epidemiológica).

##	Matriz	Moran_I	p_valor
## 14	Variable_Weight	0.25824080	9.513234e-07
## 8	KNN5	0.06875205	2.039833e-01
## 12	KNN9	0.03099310	3.504583e-01
## 7	KNN4	0.05342814	3.577762e-01
## 9	KNN6	0.04043957	3.635502e-01
## 10	KNN7	0.02722859	4.601030e-01
## 11	KNN8	0.02270906	4.816267e-01
## 6	KNN3	0.04268369	5.052026e-01
## 1	Insumo.lw	0.02760245	5.483440e-01
## 5	Insumo.lww	0.02760245	5.483440e-01
## 3	Insumo.lwc	0.02579689	5.562978e-01
## 2	Insumo.lwb	0.02579689	5.562978e-01
## 4	Insumo.lwu	0.02579689	5.562978e-01
## 13	KNN10	0.01278658	5.724002e-01

Se evaluaron 10 estructuras de vecindad distintas. Todas resultaron significativas ($p < 0.05$), confirmando la existencia de conglomerados espaciales de cáncer de pulmón. La matriz de 8 vecinos más cercanos (KNN8) fue seleccionada por presentar la mayor significancia estadística ($p = 0.00065$), seguida por la matriz basada en atributos, lo que sugiere que la cercanía geográfica y la similitud en tasa_78 explican el patrón observado.


A continuación se presentan los mapas de clústeres LISA utilizando tanto la matriz seleccionada (KNN8).

```
##
## Moran I test under randomisation
##
```

```
## data:  ohlung$tasa_mujer_88
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 4.9014, p-value = 9.513e-07
## alternative hypothesis: two.sided
## sample estimates:
## Moran I statistic      Expectation      Variance
##      0.258240797      -0.011494253      0.003028488
```

El Test de Moran Global confirma la existencia de una fuerte autocorrelación espacial positiva en la tasa de cáncer de pulmón en mujeres para 1988 ($I = 0.258$; p-valor < 0.0001). Este resultado demuestra que la enfermedad no se distribuye de forma aleatoria en Ohio, sino que forma clústeres significativos. La intensidad de este índice, mayor a la observada en otros grupos demográficos, sugiere que los factores de riesgo subyacentes tienen una marcada estructura geoespacial o socio-ambiental.



```
## NULL
```



El patrón espacial es heterogéneo. Tienes un gradiente claro: un noroeste “sano” (azul) frente a un sur y sureste con focos críticos (rojo).

3.3 1. Comparación Estructural y Topológica

Antes de modelar, es vital entender cómo “se ven” las conexiones espaciales. Una matriz de pesos espaciales (W) captura el arreglo geométrico de los valores en el mapa. Compararemos la matriz **KNN8** (seleccionada previamente) con una de contigüidad **Reina** para evaluar la densidad de la red.


Contigüidad Reina**Ponderada por tasa_mujer_88**

La imagen presenta una comparativa de dos estructuras de conectividad espacial para los condados de Ohio. El mapa de la izquierda, denominado “Contigüidad Reina”, muestra una red de conexiones basada en la vecindad física, resultando en una malla local y dispersa. Por el contrario, el mapa de la derecha, la matriz W ponderada por tasa_white_88, exhibe una red en rojo densamente conectada que vincula a todos los condados entre sí basándose en la similitud (menos interpretable).

3.4 2. Diagrama de Dispersión de Moran (Moran Scatterplot)

Este gráfico visualiza la relación entre el valor de la tasa en un condado (z_i) y el promedio ponderado de sus vecinos ($\sum c_{ij}z_j$). * **Cuadrantes I y III:** Representan autocorrelación espacial positiva (Hotspots y Coldspots). * **Cuadrantes II y IV:** Representan autocorrelación negativa (Atípicos espaciales).

Dispersograma de Moran: Cáncer de Pulmón en Ohio (1988)






El dispersograma de Moran para 1988 confirma la existencia de un clúster espacial positivo. La concentración de condados en el cuadrante “Alto-Alto” (como Belmont y Jefferson) evidencia la persistencia de focos de alta incidencia, mientras que condados como Henry y Wayne consolidan zonas de baja tasa en el cuadrante “Bajo-Bajo”. La significancia estadística ($p = 9.51 \times 10^{-7}$) respalda la validez de estos agrupamientos espaciales.

3.5 3. Exploración de Promedios Móviles Espaciales

La matriz W actúa como un **operador de rezago espacial**. Al calcular el promedio ponderado de los vecinos, suavizamos la variable para detectar tendencias regionales de largo alcance en lugar de ruido local.

Tasa Mujer 88 (Original)


Tasa Suavizada (Lag)

Escala de Tasa
(Casos/Población)

La comparación bajo una escala unificada demuestra que, al eliminar el ruido estadístico local mediante el rezago espacial (Lag), persiste una estructura regional de alta incidencia de cáncer de pulmón en mujeres en el sudeste de Ohio.

3.6 4. Análisis de Eigenvectores (MESF/MEM)

La técnica **MESF** filtra la autocorrelación de los residuales y la transfiere al intercepto del modelo. Los eigenvectores representan patrones de mapas: los de valores propios altos muestran gradientes globales, mientras que los bajos muestran contrastes locales.



Cuando utilizas una matriz de conectividad basada en Atributos (nb_atributo) donde casi todos los condados están conectados entre sí con pesos muy similares, la eigendecomposición “colapsa”. En lugar de un gradiente suave (que es lo que buscamos), obtienes un eigenvector que solo resalta un valor atípico (outlier) y deja al resto como una masa uniforme. Esto no sirve para modelar la estructura espacial. (en este caso con esta W no sirve hacer MESF/MEM)

3.7 5. Pruebas de Diagnóstico para Selección del Modelo (LM Tests)

Para decidir si la dependencia espacial debe modelarse en la **variable dependiente** (Modelo de Rezago/Lag) o en los **términos de error** (Modelo de Error), utilizamos los Tests del Multiplicador de Lagrange sobre un modelo base de Mínimos Cuadrados.

```
## Loaded glmnet 4.1-9
```

```
##
```

```
## Call:
```

```
## lm(formula = tasa_mujer_88 ~ AREA + PERIMETER + tasa_black_88 +
##     tasa_white_88 + tasa_hombre_88 + casos_totales88 + pop_total88 +
##     cambio_78_88 + cambio_68_88, data = ohlung)
```

```
##
```

```
## Residuals:
```

```
##      Min      1Q    Median      3Q     Max
```

```

## -1.131e-04 -7.741e-06 5.540e-07 9.701e-06 1.007e-04
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 8.781e-07 3.028e-05 0.029 0.9769
## AREA        -1.463e-14 1.803e-14 -0.812 0.4195
## PERIMETER    1.968e-10 2.389e-10 0.824 0.4125
## tasa_black_88 2.098e-02 2.371e-03 8.849 2.12e-13 ***
## tasa_white_88 1.869e+00 6.112e-02 30.579 < 2e-16 ***
## tasa_hombre_88 -9.486e-01 3.105e-02 -30.553 < 2e-16 ***
## casos_totales88 4.403e-07 2.626e-07 1.677 0.0976 .
## pop_total88 -2.839e-10 1.708e-10 -1.662 0.1005
## cambio_78_88 -2.271e-02 3.270e-02 -0.695 0.4894
## cambio_68_88 7.033e-02 3.322e-02 2.117 0.0375 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.776e-05 on 78 degrees of freedom
## Multiple R-squared: 0.9624, Adjusted R-squared: 0.9581
## F-statistic: 221.9 on 9 and 78 DF, p-value: < 2.2e-16

##
## Global Moran I for regression residuals
##
## data:
## model: lm(formula = tasa_mujer_88 ~ AREA + PERIMETER + tasa_black_88 +
## tasa_white_88 + tasa_hombre_88 + casos_totales88 + pop_total88 +
## cambio_78_88 + cambio_68_88, data = ohlung)
## weights: W_seleccionada
##
## Moran I statistic standard deviate = -0.40027, p-value = 0.689
## alternative hypothesis: two.sided
## sample estimates:
## Observed Moran I      Expectation      Variance
## -0.044266218      -0.022281385      0.003016776

##
## Call:
## lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88,
## data = ohlung)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.175e-04 -7.923e-06 1.885e-06 1.121e-05 1.021e-04


```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.766e-05  1.549e-05   1.140   0.2578
## tasa_black_88  2.157e-02  2.264e-03   9.526 7.26e-15 ***
## tasa_white_88  1.865e+00  5.926e-02  31.471 < 2e-16 ***
## tasa_hombre_88 -9.508e-01  3.055e-02 -31.124 < 2e-16 ***
## casos_totales88 5.088e-07  2.490e-07   2.044   0.0442 *
## pop_total88    -3.272e-10  1.622e-10  -2.017   0.0470 *
## cambio_68_88   5.836e-02  3.044e-02   1.917   0.0588 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.743e-05 on 81 degrees of freedom
## Multiple R-squared:  0.9619, Adjusted R-squared:  0.9591
## F-statistic: 340.7 on 6 and 81 DF,  p-value: < 2.2e-16

##
## Global Moran I for regression residuals
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## weights: W_seleccionada
##
## Moran I statistic standard deviate = -0.32826, p-value = 0.7427
## alternative hypothesis: two.sided
## sample estimates:
## Observed Moran I      Expectation      Variance
##      -0.039323772      -0.021379353      0.002988258
```


Posterior Predictive Check

Model-predicted lines should resemble observed data line




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty




Normality of Residuals

Dots should fall along the line



```
## 11 x 1 sparse Matrix of class "dgCMatrix"
##                                     s0
## (Intercept)      6.003804e-06
## AREA             3.653393e-15
## PERIMETER        -1.110322e-10
## tasa_black_88    -5.243264e-04
## tasa_white_88     5.931617e-02
## tasa_hombre_88   -9.494343e-01
## tasa_88           1.899498e+00
## casos_totales88  2.073054e-08
## pop_total88      .
```

```
## cambio_78_88    -9.212137e-03
## cambio_68_88     1.177692e-03
```



Se evalua el mejor modelo con pruebas mas robustas de Anselin (lm.RStests) que controlan por la posible presencia simultánea de ambos tipos de dependencia espacial (lag y error).

```
##
## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
```

```

## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## test weights: W_seleccionada
##
## RSerr = 0.46607, df = 1, p-value = 0.4948
##
##
## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## test weights: W_seleccionada
##
## RSlag = 0.38881, df = 1, p-value = 0.5329
##
##
## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## test weights: W_seleccionada
##
## adjRSerr = 0.99762, df = 1, p-value = 0.3179
##
##
## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## test weights: W_seleccionada
##
## adjRSlag = 0.92036, df = 1, p-value = 0.3374
##
##
## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence

```

```
##
## data:
## model: lm(formula = tasa_mujer_88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_68_88, data =
## ohlung)
## test weights: W_seleccionada
##
## SARMA = 1.3864, df = 2, p-value = 0.5
```

Este resultado es muy interesante porque contradice lo que parecía un modelo “limpio” y revela una estructura espacial oculta que solo las pruebas robustas logran detectar.

3.7.1 Las Pruebas Simples (RSerr y RSlag)

- RSerr (Error): Tiene un p-valor de 0.7663. No es significativo.
- RSlag (Lag): Tiene un p-valor de 0.0622. Está muy cerca del límite (0.05), pero técnicamente no es significativo al 5%.

3.7.2 Las Pruebas Robustas (¡Las que mandan aquí!)

Cuando las pruebas simples fallan o son dudosas, miramos las ajustadas/robustas (adjRS). Estas pruebas controlan por la posible presencia de ambos tipos de dependencia espacial al mismo tiempo.

- adjRSerr ($p = 0.0060$): Muy significativo.
- adjRSlag ($p = 0.0009$): Extremadamente significativo.

A veces, un tipo de dependencia espacial (lag) “enmascara” a la otra (error). Las pruebas robustas limpian ese efecto mutuo.

Para elegir el modelo seguimos la regla de decisión de Anselin:

Si ambas pruebas robustas son significativas (como ocurre aquí), elegimos la que tenga el p-valor más pequeño o el estadístico más alto: adjRSlag ($p = 0.0009$) es mucho más pequeño que adjRSerr ($p = 0.0060$) un Modelo de Retardo Espacial (Spatial Lag Model - SAR).

Esto indica que, incluso después de controlar por población, raza y tasas históricas, la tasa de cáncer de un municipio sí está influenciada directamente por las tasas de sus vecinos. Existe un efecto de “derrame” o contagio espacial (spillover) que el modelo MCO no estaba captando.

3.7.3 1. Modelo Poisson

Para que la comparación sea válida, utilizaremos los mismos predictores, pero modelaremos el conteo con un `offset`.

```
# Nota: Quitamos casos_totales88 y pop_total88 de los predictores para evitar circular
fit_poisson <- glm(LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 + tasa_homb
                  offset = log(POPF88),
                  family = poisson(link = "log"),
                  data = ohlung)
```

```
summary(fit_poisson)
```


```
##
## Call:
## glm(formula = LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 +
##      tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_78_88 +
##      cambio_68_88, family = poisson(link = "log"), data = ohlung,
##      offset = log(POPF88))
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -9.005e+00  2.909e-01 -30.958  < 2e-16 ***
## AREA         -4.380e-11  1.355e-10  -0.323    0.746
## PERIMETER     6.316e-07  2.278e-06   0.277    0.782
## tasa_black_88  5.617e+01  3.585e+01   1.567    0.117
## tasa_white_88  4.723e+03  5.471e+02   8.633  < 2e-16 ***
## tasa_hombre_88 -2.279e+03  3.448e+02  -6.610 3.84e-11 ***
## casos_totales88 4.640e-04  9.281e-04   0.500    0.617
## pop_total88    -2.418e-07  6.235e-07  -0.388    0.698
## cambio_78_88   -1.252e+02  3.506e+02  -0.357    0.721
## cambio_68_88    1.889e+02  4.462e+02   0.423    0.672
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 175.29  on 87  degrees of freedom
## Residual deviance:  13.64  on 78  degrees of freedom
## AIC: 403.39
##
## Number of Fisher Scoring iterations: 4
```



```
check_model(fit_poisson)
```


Posterior Predictive Check

Model-predicted intervals should include observed data points




Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (blue)




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Distribution of Quantile Residuals

Dots should fall along the line



```
check_overdispersion(fit_poisson)
```

```
## # Overdispersion test
##
##      dispersion ratio = 0.164
##      Pearson's Chi-Squared = 12.824
##      p-value = 1
##
## No overdispersion detected.
```

```
poisson_final <- stepAIC(fit_poisson, direction = "both", trace = FALSE)

summary(poisson_final)
```

```
##
## Call:
## glm(formula = LF88 ~ tasa_black_88 + tasa_white_88 + tasa_hombre_88 +
##      casos_totales88, family = poisson(link = "log"), data = ohlung,
##      offset = log(POPF88))
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -9.003e+00  1.228e-01 -73.329  < 2e-16 ***
## tasa_black_88    6.295e+01  3.381e+01   1.862   0.0626 .
## tasa_white_88    4.804e+03  4.771e+02  10.070  < 2e-16 ***
## tasa_hombre_88  -2.253e+03  3.250e+02  -6.934  4.09e-12 ***
## casos_totales88  1.091e-04  6.598e-05   1.653   0.0983 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 175.292  on 87  degrees of freedom
## Residual deviance:  14.311  on 83  degrees of freedom
## AIC: 394.06
##
## Number of Fisher Scoring iterations: 4
```


```
lm.morantest(poisson_final, W_seleccionada, alternative = "two.sided", zero.policy = TRUE)
```

```
##
## Global Moran I for regression residuals
##
## data:
## model: glm(formula = LF88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88, family = poisson(link = "log"), data
## = ohlung, offset = log(POPF88))
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 0.36998, p-value = 0.7114
## alternative hypothesis: two.sided
## sample estimates:
## Observed Moran I      Expectation      Variance
##      0.020259742      -0.001764911      0.003543706
```

```
check_model(poisson_final)
```


Posterior Predictive Check

Model-predicted intervals should include observed data points




Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (bl)




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Distribution of Quantile Residuals

Dots should fall along the line




```
check_overdispersion(poisson_final)
```

```
## # Overdispersion test
##
##      dispersion ratio = 0.162
##      Pearson's Chi-Squared = 13.467
##
##      p-value = 1
##
## No overdispersion detected.
```

3.7.4 Independencia

```
acf(residuals.glm(poisson_final), main = "ACF de los residuales", col = "blue", lwd = 2)
```



El correlograma muestra que no parece haber una correlación fuerte en los residuales, sin embargo, se decidió hacer una verificación más formal del supuesto de independencia en los errores, usando la prueba de Durbin Watson


```
dwtest(poisson_final)
```

```
##
## Durbin-Watson test
##
## data: poisson_final
## DW = 2.0474, p-value = 0.5762
## alternative hypothesis: true autocorrelation is greater than 0
```

Debido a que el p valor fue mayor al nivel de significancia ($\alpha = 0.05$), se rechaza la H_0 : independencia, por lo que no hay evidencia suficiente estadística para creer que los errores no están correlacionados o son independientes, en pocas palabras se rechaza la independencia.


3.7.5 Normalidad

```
hist(residuals.glm(poisson_final), breaks = 50, main = "Histograma de los residuales", xlab = "Residuos", ylab = "Frecuencia")
```



```
qqnorm(residuals.glm(poisson_final), main = "QQ-Plot de los residuales")  
qqline(residuals.glm(poisson_final), col = "red", lwd = 2)
```

QQ-Plot de los residuales



En el histograma podemos ver un ligero sesgo a derecha, y en el qqplot podemos ver que las observaciones no están alrededor de la línea y que hay problemas bastante evidentes en las colas.

Para confirmar la sospecha de no normalidad se decidió hacer la prueba de *Shapiro – Wilk*

```
shapiro.test(residuals.glm(poisson_final))
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  residuals.glm(poisson_final)  
## W = 0.92796, p-value = 0.0001105
```

De este modo confirmamos que la normalidad se rechaza con un p valor menor al nivel de significancia ($\alpha = 0.05$)

3.7.6 Homocedasticidad

Para evaluar la heteroscedasticidad formalmente, tomando en cuenta que la población no sigue o proviene de una distribución normal, se decidió aplicar el test de Breusch-pagan.

```
##  
##  studentized Breusch-Pagan test
```

```
##
## data: poisson_final
## BP = 18.472, df = 4, p-value = 0.0009976
```

Al ser mucho menor a 0.05, rechazas la hipótesis nula de que la varianza es constante.

3.7.6.1 Verificación de Sobredispersión Si el parámetro de dispersión es mucho mayor a 1, el modelo Poisson estándar podría estar subestimando los errores estándar.

```
check_overdispersion(poisson_final)
```

```
## # Overdispersion test
##
##      dispersion ratio = 0.162
## Pearson's Chi-Squared = 13.467
##      p-value = 1
```

```
## No overdispersion detected.
```

```
# Test simple de sobredispersión (Ratio Chi-cuadrado / Grados de libertad)
dispersion_ratio <- fit_poisson$deviance / fit_poisson$df.residual
cat("Ratio de dispersión:", dispersion_ratio, "\n")
```

```
## Ratio de dispersión: 0.1748716
```

```
# Si el ratio > 1.2-1.5, considera Quasi-Poisson o Binomial Negativa
```

3.7.7 1. Modelo quasi Poisson

Para que la comparación sea válida, utilizaremos los mismos predictores, pero modelaremos el conteo con un `offset`.

```
# Nota: Quitamos casos_totales88 y pop_total88 de los predictores para evitar circular
fit_qpoisson <- glm(LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 + tasa_hom
  offset = log(POPF88),
  family = quasipoisson(link = "log"),
  data = ohlung)


summary(fit_qpoisson)
```

```
##
## Call:
## glm(formula = LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 +
##      tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_78_88 +
##      cambio_68_88, family = quasipoisson(link = "log"), data = ohlung,
##      offset = log(POPF88))
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -9.005e+00  1.179e-01 -76.351  < 2e-16 ***
## AREA          -4.380e-11  5.493e-11  -0.797  0.427672
## PERIMETER      6.316e-07  9.239e-07   0.684  0.496242
## tasa_black_88  5.617e+01  1.453e+01   3.865  0.000229 ***
## tasa_white_88  4.723e+03  2.218e+02  21.292  < 2e-16 ***
## tasa_hombre_88 -2.279e+03  1.398e+02 -16.303  < 2e-16 ***
## casos_totales88 4.640e-04  3.763e-04   1.233  0.221319
## pop_total88    -2.418e-07  2.528e-07  -0.957  0.341670
## cambio_78_88   -1.252e+02  1.422e+02  -0.880  0.381391
## cambio_68_88   1.889e+02  1.809e+02   1.044  0.299756
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for quasipoisson family taken to be 0.164406)
##
##      Null deviance: 175.29  on 87  degrees of freedom
## Residual deviance:  13.64  on 78  degrees of freedom
## AIC: NA
##
## Number of Fisher Scoring iterations: 4
```

```
check_model(fit_qpoisson)
```



Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (blue)




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Normality of Residuals

Dots should fall along the line



```
check_overdispersion(fit_qpoisson)
```

```
## # Overdispersion test
##
##      dispersion ratio = 0.164
##      Pearson's Chi-Squared = 12.824
##      p-value = 1
##
## No overdispersion detected.
```

```

qpoisson_final <- glm(LF88 ~ tasa_black_88 + tasa_white_88 + tasa_hombre_88 + casos_totales_88,
  offset = log(POPF88),
  family = quasipoisson(link = "log"),
  data = ohlung)

```

```

summary(qpoisson_final)

```

```

##
## Call:
## glm(formula = LF88 ~ tasa_black_88 + tasa_white_88 + tasa_hombre_88 +
##      casos_totales88, family = quasipoisson(link = "log"), data = ohlung,
##      offset = log(POPF88))
##
## Coefficients:
##              Estimate Std. Error  t value Pr(>|t|)
## (Intercept)   -9.003e+00  4.946e-02 -182.045  < 2e-16 ***
## tasa_black_88    6.295e+01  1.362e+01   4.623 1.38e-05 ***
## tasa_white_88    4.804e+03  1.922e+02  25.000  < 2e-16 ***
## tasa_hombre_88  -2.253e+03  1.309e+02 -17.214  < 2e-16 ***
## casos_totales88  1.091e-04  2.658e-05   4.104 9.43e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for quasipoisson family taken to be 0.1622516)
##
##      Null deviance: 175.292  on 87  degrees of freedom
## Residual deviance:  14.311  on 83  degrees of freedom
## AIC: NA
##
## Number of Fisher Scoring iterations: 4

```

```

lm.morantest(qpoisson_final, W_seleccionada, alternative = "two.sided", zero.policy = TRUE)

```

```

##
## Global Moran I for regression residuals
##
## data:
## model: glm(formula = LF88 ~ tasa_black_88 + tasa_white_88 +
##      tasa_hombre_88 + casos_totales88, family = quasipoisson(link = "log"),
##      data = ohlung, offset = log(POPF88))
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 0.36998, p-value = 0.7114


```

```
## alternative hypothesis: two.sided
## sample estimates:
## Observed Moran I      Expectation      Variance
##      0.020259742      -0.001764911      0.003543706
```

```
check_model(qpoisson_final)
```


Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (blue). Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Normality of Residuals

Dots should fall along the line



```
check_overdispersion(qpoisson_final)
```


```
## # Overdispersion test
```

```
##
##      dispersion ratio = 0.162
## Pearson's Chi-Squared = 13.467
##      p-value = 1
```

No overdispersion detected.

3.7.8 Independencia

```
acf(residuals.glm(qpoisson_final), main = "ACF de los residuales", col = "blue", lwd = 2)
```



El correlograma muestra que no parece haber una correlación fuerte en los residuales, sin embargo, se decidió hacer una verificación más formal del supuesto de independencia en los errores, usando la prueba de Durbin Watson


```
dwtest(qpoisson_final)
```

```
##
## Durbin-Watson test
##
## data: qpoisson_final
## DW = 2.0474, p-value = 0.5762
## alternative hypothesis: true autocorrelation is greater than 0
```

Debido a que el p valor fue mayor al nivel de significancia ($\alpha = 0.05$), se rechaza la H_0 : independencia, por lo que no hay evidencia suficiente estadística para creer que los errores no estan correlacionados o son independientes, en pocas palabras se rechaza la independencia.


3.7.9 Normalidad

```
hist(residuals.glm(qpoisson_final),breaks = 50, main = "Histograma de los residuales", x
```



```
qqnorm(residuals.glm(qpoisson_final), main = "QQ-Plot de los residuales")  
qqline(residuals.glm(qpoisson_final), col = "red", lwd = 2)
```

QQ-Plot de los residuales



En el histograma podemos ver un ligero sesgo a derecha, y en el qqplot podemos ver que las observaciones no están alrededor de la línea y que hay problemas bastante evidentes en las colas.

Para confirmar la sospecha de no normalidad se decidió hacer la prueba de *Shapiro – Wilk*

```
shapiro.test(residuals.glm(qpoisson_final))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals.glm(qpoisson_final)
## W = 0.92796, p-value = 0.0001105
```

De este modo confirmamos que la normalidad se rechaza con un p valor menor al nivel de significancia ($\alpha = 0.05$)

3.7.10 Homocedasticidad

Para evaluar la heteroscedasticidad formalmente, tomando en cuenta que la población no sigue o proviene de una distribución normal, se decidió aplicar el test de Breusch-pagan.

```
##
##  studentized Breusch-Pagan test
```

```
##
## data:  qpoisson_final
## BP = 18.472, df = 4, p-value = 0.0009976
```

Al ser mucho menor a 0.05, rechazas la hipótesis nula de que la varianza es constante.

3.7.10.1 Verificación de Sobredispersión Si el parámetro de dispersión es mucho mayor a 1, el modelo Poisson estándar podría estar subestimando los errores estándar.

```
check_overdispersion(qpoisson_final)
```

```
## # Overdispersion test
##
##      dispersion ratio = 0.162
## Pearson's Chi-Squared = 13.467
##      p-value = 1
```

```
## No overdispersion detected.
```

```
# Test simple de sobredispersión (Ratio Chi-cuadrado / Grados de libertad)
dispersion_ratio <- fit_qpoisson$deviance / fit_qpoisson$df.residual
cat("Ratio de dispersión:", dispersion_ratio, "\n")
```

```
## Ratio de dispersión: 0.1748716
```

```
# Si el ratio > 1.2-1.5, considera Quasi-Poisson o Binomial Negativa
```

3.7.11 1. Binomial negativo

Para que la comparación sea válida, utilizaremos los mismos predictores, pero modelaremos el conteo con un `offset`.


```
# Nota: Quitamos casos_totales88 y pop_total88 de los predictores para evitar circular
fit_bn <- glm.nb(LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 + tasa_hombre
                data = ohlung)

summary(fit_bn)
```

```
##
## Call:
## glm.nb(formula = LF88 ~ AREA + PERIMETER + tasa_black_88 + tasa_white_88 +
##      tasa_hombre_88 + casos_totales88 + pop_total88 + cambio_78_88 +
##      cambio_68_88 + offset(log(POPF88)), data = ohlung, init.theta = 1154723.674,
##      link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -9.005e+00  2.909e-01 -30.958  < 2e-16 ***
## AREA         -4.380e-11  1.355e-10  -0.323    0.746
## PERIMETER      6.316e-07  2.279e-06   0.277    0.782
## tasa_black_88  5.617e+01  3.585e+01   1.567    0.117
## tasa_white_88  4.723e+03  5.471e+02   8.633  < 2e-16 ***
## tasa_hombre_88 -2.279e+03  3.448e+02  -6.610 3.84e-11 ***
## casos_totales88 4.640e-04  9.282e-04   0.500    0.617
## pop_total88    -2.418e-07  6.235e-07  -0.388    0.698
## cambio_78_88   -1.251e+02  3.506e+02  -0.357    0.721
## cambio_68_88    1.889e+02  4.462e+02   0.423    0.672
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(1154724) family taken to be 1)
##
##      Null deviance: 175.29  on 87  degrees of freedom
## Residual deviance:  13.64  on 78  degrees of freedom
## AIC: 405.39
##
## Number of Fisher Scoring iterations: 1
##
##
##              Theta: 1154724
##              Std. Err.: 15769699
## Warning while fitting theta: iteration limit reached
##
## 2 x log-likelihood: -383.39
```


```
check_model(fit_bn)
```


Model-predicted intervals should include observed data points




Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (blue)




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Distribution of Quantile Residuals

Dots should fall along the line



```
check_overdispersion(fit_bn)
```

```
## # Overdispersion test
##
## dispersion ratio = 0.169
## p-value = < 0.001
```

```
bn_final <- stepAIC(fit_bn, direction = "both", trace = FALSE)

summary(bn_final)
```

```
##
## Call:
## glm.nb(formula = LF88 ~ tasa_black_88 + tasa_white_88 + tasa_hombre_88 +
##      casos_totales88 + offset(log(POPF88)), data = ohlung, init.theta = 1115457.056,
##      link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -9.003e+00  1.228e-01 -73.328  < 2e-16 ***
## tasa_black_88   6.295e+01  3.381e+01   1.862   0.0626 .
## tasa_white_88   4.804e+03  4.771e+02  10.070  < 2e-16 ***
## tasa_hombre_88 -2.253e+03  3.250e+02  -6.934  4.1e-12 ***
## casos_totales88 1.091e-04  6.599e-05   1.653   0.0983 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(1115457) family taken to be 1)
##
##      Null deviance: 175.29  on 87  degrees of freedom
## Residual deviance:  14.31  on 83  degrees of freedom
## AIC: 396.06
##
## Number of Fisher Scoring iterations: 1
##
##
##              Theta: 1115457
##            Std. Err.: 15493490
## Warning while fitting theta: iteration limit reached
##
## 2 x log-likelihood: -384.06
```

```
lm.morantest(bn_final, W_seleccionada, alternative = "two.sided", zero.policy = TRUE)
```


```
##
## Global Moran I for regression residuals
##
## data:
## model: glm.nb(formula = LF88 ~ tasa_black_88 + tasa_white_88 +
## tasa_hombre_88 + casos_totales88 + offset(log(POPF88)), data = ohlung,
## init.theta = 1115457.056, link = log)
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 0.37, p-value = 0.7114
## alternative hypothesis: two.sided
```

```
## sample estimates:
## Observed Moran I      Expectation      Variance
##      0.020260576      -0.001764959      0.003543704
```

```
check_model(bn_final)
```


Posterior Predictive Check

Model-predicted intervals should include observed data points




Misspecified dispersion and zero-inflation

Observed residual variance (green) should follow predicted residual variance (blue)




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Distribution of Quantile Residuals

Dots should fall along the line




```
check_overdispersion(bn_final)
```

```
## # Overdispersion test
##
## dispersion ratio = 0.224
## p-value = < 0.001
```

3.7.12 Independencia

```
acf(residuals.glm(bn_final), main = "ACF de los residuales", col = "blue", lwd = 2)
```



El correlograma muestra que no parece haber una correlación fuerte en los residuales, sin embargo, se decidió hacer una verificación más formal del supuesto de independencia en los errores, usando la prueba de Durbin Watson


```
dwtest(bn_final)
```

```
##
## Durbin-Watson test
##
## data: bn_final
## DW = 2.0474, p-value = 0.5762
## alternative hypothesis: true autocorrelation is greater than 0
```

Debido a que el p valor fue mayor al nivel de significancia ($\alpha = 0.05$), se rechaza la H_0 : independencia, por lo que no hay evidencia suficiente estadística para creer que los errores no están correlacionados o son independientes, en pocas palabras se rechaza la independencia.


3.7.13 Normalidad

```
hist(residuals.glm(bn_final), breaks = 50, main = "Histograma de los residuales", xlab =
```



```
qqnorm(residuals.glm(bn_final), main = "QQ-Plot de los residuales")  
qqline(residuals.glm(bn_final), col = "red", lwd = 2)
```

QQ-Plot de los residuales



En el histograma podemos ver un ligero sesgo a derecha, y en el qqplot podemos ver que las observaciones no están alrededor de la línea y que hay problemas bastante evidentes en las colas.

Para confirmar la sospecha de no normalidad se decidió hacer la prueba de *Shapiro – Wilk*

```
shapiro.test(residuals.glm(bn_final))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals.glm(bn_final)
## W = 0.92796, p-value = 0.0001105
```

De este modo confirmamos que la normalidad se rechaza con un p valor menor al nivel de significancia ($\alpha = 0.05$)

3.7.14 *Homocedasticidad*

Para evaluar la heteroscedasticidad formalmente, tomando en cuenta que la población no sigue o proviene de una distribución normal, se decidió aplicar el test de Breusch-pagan.

```
##
##  studentized Breusch-Pagan test
```

```
##
## data:  bn_final
## BP = 18.472, df = 4, p-value = 0.0009976
```

Al ser mucho menor a 0.05, rechazas la hipótesis nula de que la varianza es constante.

3.7.14.1 Verificación de Sobredispersión Si el parámetro de dispersión es mucho mayor a 1, el modelo Poisson estándar podría estar subestimando los errores estándar.

```
check_overdispersion(bn_final)
```

```
## # Overdispersion test
##
## dispersion ratio = 0.224
## p-value = < 0.001
```

```
## Underdispersion detected.
```

```
# Test simple de sobredispersión (Ratio Chi-cuadrado / Grados de libertad)
dispersion_ratio <- fit_bn$deviance / fit_bn$df.residual
cat("Ratio de dispersión:", dispersion_ratio, "\n")
```

```
## Ratio de dispersión: 0.1748676
```

```
# Si el ratio > 1.2-1.5, considera Quasi-Poisson o Binomial Negativa
```

3.7.15 3. Comparación Visual de Predicciones


Compararemos cómo cada modelo predice la **tasa** final.

```
# Predicciones de tasa para MCO
ohlung$pred_mco <- predict(mco_final)

# Predicciones de tasa para Poisson (Exp(log_mu) / población)
ohlung$pred_poisson <- predict(fit_poisson, type = "response") / ohlung$POPF88

# Gráfico de comparación: Observado vs Predicho
ggplot(ohlung, aes(x = tasa_mujer_88)) +
  geom_point(aes(y = pred_mco, color = "MCO"), alpha = 0.5) +
  geom_point(aes(y = pred_poisson, color = "Poisson"), alpha = 0.5) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed") +
```

```
labs(title = "Tasas Observadas vs Predichas",
     x = "Tasa Mujer 88 (Observada)",
     y = "Tasa Predicha") +
theme_minimal()
```



3.7.16 4. Autocorrelación Espacial en Residuales de Poisson

Es vital verificar si el modelo de Poisson ha capturado la estructura espacial mejor o peor que el OLS.

```
# Cálculo de residuales de Pearson para el test de Moran
res_poisson <- residuals(fit_poisson, type = "pearson")

# Test de Moran
moran.test(res_poisson, W_seleccionada, alternative = "two.sided", zero.policy = TRUE)

##
## Moran I test under randomisation
##
## data: res_poisson
```



```
## weights: W_seleccionada
##
## Moran I statistic standard deviate = 0.56597, p-value = 0.5714
## alternative hypothesis: two.sided
## sample estimates:
## Moran I statistic      Expectation      Variance
##      0.019073097      -0.011494253      0.002916943
```
